

NOTE MÉTHODOLOGIQUE – PROJET DATAVIZ

Répartition des ressources et charge de travail

1. Problème choisi

L'organisation étudiée ne dispose pas d'une vision claire de la manière dont la charge de travail est répartie entre les différents centres, phases projets et modules informatiques. Plusieurs signaux internes indiquent que certaines équipes sont fortement sollicitées tandis que d'autres sont sous-utilisées. Cette situation pourrait entraîner des retards, une surcharge individuelle, une sous-affectation de certaines ressources et une baisse globale de performance.

Le problème identifié est donc le suivant :

L'organisation manque d'un outil permettant de visualiser et d'analyser l'équilibre de la charge de travail afin de repérer les zones de surcharge ou de sous-activité et d'améliorer l'allocation des ressources.

Ce problème soulève la nécessité d'effectuer une analyse structurée pour comprendre comment la charge est réellement distribuée dans l'entreprise.

2. Dataset retenu

Le dataset utilisé provient du fichier « data_complet_v2.xlsx ». Il contient environ 7 800 enregistrements décrivant les activités réalisées dans différents centres techniques et sur plusieurs modules informatiques. Chaque ligne représente une activité ou une intervention, associée à un centre, un module, une phase projet et un poste (utilisateur).

Les principales colonnes retenues sont :

- **Centre** : centre de travail responsable de l'activité.
- **NOM_SI** : nom du module ou projet concerné.
- **Types_phases** : phase du projet (RÉALISATION, MAINTENANCE, ÉTUDE, AUTRES).
- **utilisateur_id2** : identifiant du poste réalisant l'activité.
- **ChargeTotaleEstimee** : charge prévue (en heures).
- **ChargeTotaleActualisee** : charge réellement réalisée (en heures).

Ces données sont pertinentes car elles couvrent l'ensemble des dimensions nécessaires à l'analyse : centres, phases, modules et postes, ainsi que leurs charges de travail estimées et réelles.

3. Technologies utilisées

Les technologies mobilisées pour ce projet sont les suivantes :

- **Python (pandas, numpy, matplotlib)** : analyse exploratoire, nettoyage, calcul des indicateurs, agrégations.
- **Jupyter Notebook** : réalisation des notebooks d'EDA, de préparation et d'expérimentation technique.
- **Git et GitHub** : versionnement, organisation du projet et dépôt final.
- **PyInstaller** : génération d'un exécutable (.exe) pour livrer une application client automatisant l'ensemble du pipeline de données.
- **Tableau Public** : construction du tableau de bord final et visualisation interactive.

Ces outils ont été choisis pour leur complémentarité et leur pertinence dans un workflow complet de data visualisation.

4. Hypothèses et tests réalisés

À partir du problème identifié, plusieurs hypothèses ont été formulées et testées à l'aide du dataset.

H1 : Certains centres sont plus chargés que d'autres.

Analyse : agrégation des charges totales réelles par centre.

Résultat : certains centres (par exemple CDAD-T, CDAD-BO, CDAD-R) concentrent une part très importante de la charge totale, validant l'hypothèse.

H2 : Certaines phases consomment plus de ressources.

Analyse : somme des charges réelles par phase.

Résultat : la phase RÉALISATION domine largement en volume d'heures, confirmant l'hypothèse.

H3 : Quelques modules absorbent la majorité de la charge.

Analyse : charge totale réelle par module.

Résultat : certains modules, comme INITIATIVE PODEV 2024, GEOSTAR_NG ou GEMAPAL, sont fortement consommateurs.

H4 : Certains postes sont individuellement en surcharge.

Analyse : charge totale par utilisateur.

Résultat : certains postes affichent une charge réelle très élevée par rapport à la médiane, ce qui valide l'hypothèse.

H5 : Les charges réelles dépassent régulièrement les charges estimées.

Analyse : écart et taux de surcharge.

Résultat : tendance générale à la sous-estimation observée.

5. Démarche méthodologique

La démarche a été structurée en plusieurs étapes correspondant aux attendus du projet.

5.1. Audit et analyse exploratoire (Notebook 01)

- Vérification du dataset (types, valeurs manquantes, doublons, incohérences).
- Standardisation initiale des colonnes textuelles.
- Analyse univariée :
 - répartition des centres,
 - répartition des phases,
 - répartition des modules,
 - distribution des charges.
- Analyse bivariée :
 - charge par centre,
 - charge par phase,
 - charge par module,
 - charge par poste.
- Formulation d'une première interprétation des déséquilibres observés.

5.2. Nettoyage et préparation des données (Notebook 02)

- Correction des valeurs invalides (par exemple « - ») dans les charges.
- Mise en cohérence des labels (majuscule, suppression des espaces).
- Conversion rigoureuse des colonnes de charge en valeurs numériques.
- Gestion des cas particuliers :
 - centre inconnu,
 - phase non renseignée,
 - poste « - » converti en INCONNU.
- Mise en place d'une règle professionnelle pour le calcul des taux de surcharge :
 - 0 % si charge estimée = 0 et charge réelle = 0
 - NaN si charge estimée = 0 mais charge réelle > 0
 - ratio normal sinon
- Construction des agrégations nécessaires au tableau de bord :
 - par centre,
 - par phase,
 - par module,
 - centre × phase,
 - module × phase.

5.3. Construction d'un pipeline automatisé (Notebook 03)

- Définition de fonctions modulaires :
 - `load_data()`,
 - `clean_data()`,
 - `compute_indicators()`,
 - `build_aggregations()`,

- `export_data()`.
- Création d'un script Python (.py) compilable indépendamment du notebook.
- Génération d'un exécutable (.exe) permettant d'automatiser l'ensemble du pipeline et de produire le fichier final « `data_aggregations.xlsx` » pour le responsable.

5.4. Élaboration du tableau de bord Tableau Public

- Intégration du fichier agrégé.
- Création d'indicateurs clés (cartes KPI).
- Visualisations principales :
 - charge réelle vs estimée par centre,
 - répartition par phase,
 - Top 5 des modules consommateurs,
 - matrice centre × phase.
- Mise en place de filtres et interactions.

6. Synthèse des résultats

Les analyses montrent des déséquilibres importants dans la répartition de la charge :

- Trois centres concentrent la majorité de la charge totale.
- La phase RÉALISATION domine nettement les autres phases.
- Quelques modules consomment un volume disproportionné d'heures.
- Certains postes portent une charge très au-dessus de la médiane.
- Les charges réelles sont globalement supérieures aux charges estimées, signe d'une sous-évaluation des charges initiales.

Ces résultats confirment la nécessité d'un tableau de bord de suivi afin d'améliorer l'allocation des ressources et la gestion des projets.

7. Limites et pistes d'amélioration

Limites identifiées :

- Certaines charges estimées ou réelles sont nulles, ce qui peut biaiser les ratios.
- Quelques valeurs textuelles incohérentes reflètent probablement des erreurs de saisie.

Améliorations possibles :

- Construire un modèle prédictif de surcharge.
- Automatiser la récupération des données en connexion au SI de l'entreprise.